

Sistemas Inteligentes: Redes neurais para estimação de sistemas senoidais

Nelson Carlos de Sousa Campos

Maio de 2016

1 Introdução

A estimação de frequências de sinais senoidais é um importante problema na teoria e aplicação de comunicações digitais e processamento de sinais. Ele recebeu uma grande atenção nas últimas duas décadas, e muitas técnicas tem sido desenvolvidas ao longo dos anos. [3] [4]

Neste trabalho será apresentada uma abordagem para o problema da estimativa de frequência senoidal utilizando-se funções gradientes que foram obtidas a partir do modelo de redes neurais recorrentes (Rede de Hopfield). Os modelos das redes neurais desenvolvidas podem, simultaneamente, estimar frequências, amplitudes e fases de um sinal sinusoidal a partir de amostras coletadas.

2 Definição do Problema

Considere um conjunto de amostras do sinal da equação 1, onde m é o número de senóides com amplitudes, frequências e fases a serem estimadas e A_k , f_k e Φ_k são as amplitudes, frequências e fases do sinal x_n , respectivamente.

O objectivo deste trabalho consiste em elaborar um modelo para estimar frequências, amplitudes e fases dos sinusóides com base nas medições coletadas.

$$x_n = \sum_{k=0}^m A_k \cos(2\pi f_k n + \Phi_k), \text{ for } n = 0, 1, 2, \dots, N-1 \quad (1)$$

3 Redes de Hopfield

Esta seção discutirá a rede neural recorrente de Hopfield, que teve grande influência no ressurgimento das redes neurais na década de 1980.

De um ponto de vista prático, Hopfield apresentou o seu modelo de rede neural em um diagrama de circuito elétrico.[2] A Figure 1 ilustra esta rede para o caso de dois neurônios. A equação dinâmica deste circuito é representada pela forma da equação 2.




Figura 1: Rede de Hopfield com 2 neurônios

$$C \frac{dn_i(t)}{dt} = \sum_{j=1}^S T_{i,j} a_j - \frac{n_i(t)}{R_i} + I_i \quad (2)$$

onde,

$$|T_{i,j}| = \frac{1}{R_{i,j}} \quad (3)$$

Cada neurônio é representado por um amplificador inversor, que é realimentado em outro amplificador. Assim, de acordo com o teorema de Lyapunov, a rede evolui assintoticamente no tempo de modo a estabilizar no ponto estacionário da função de energia, de acordo com a equação 4.

$$\frac{dE}{dt} \leq 0 \quad (4)$$

Uma aplicação da rede de Hopfield na estimação de sinais senoidais da forma da equação 1 pode ser vista em [1]. Uma tentativa de reproduzir os experimentos não apresentaram resultados satisfatórios. Sendo assim, algumas alterações foram propostas no modelo com o intuito de contornar a solução do problema.

Utilizando o conceito de rede neural de Hopfield, pode-se aplicar o problema da estimação dos parâmetros de x_n como um problema de minimização de mínimos quadrados, conforme a equação 5, que tem como resultado a equação 6

$$\frac{dE}{dn} = \frac{d}{dn} \left[-\frac{1}{2} \sum_{n=0}^{N-1} \left[x_n - \sum_{k=1}^m A_k \cos(2\pi f_k n + \Phi_k) \right]^2 \right] \quad (5)$$

$$\frac{dE}{dn} = -2\pi \sum_{n=0}^{N-1} [f_1 A_1 \sin(2\pi f_1 + \Phi_1) + f_2 A_2 \sin(2\pi f_2 + \Phi_2)] \quad (6)$$

O gradiente da função E em relação à A_k , f_k e Φ_k são obtidos nas equações 8, 7 e 9, respectivamente, onde d_n é definido na equação 10.

$$\frac{dE}{df_k} = - \sum_{n=0}^{N-1} 2\pi n A_k \sin(2\pi n f_k + \Phi_k) d_n, \text{ for } k = 0, 1, 2, \dots, m \quad (7)$$

$$\frac{dE}{dA_k} = \sum_{n=0}^{N-1} \cos(2\pi n f_k + \Phi_k) d_n, \text{ for } k = 0, 1, 2, \dots, m \quad (8)$$

$$\frac{dE}{d\Phi_k} = - \sum_{n=0}^{N-1} A_k \sin(2\pi n f_k + \Phi_k) d_n, \text{ for } k = 0, 1, 2, \dots, m \quad (9)$$

$$dn = x_n - \sum_{i=1}^m A_i \cos(2\pi f_i n + \Phi_i) \quad (10)$$

As derivadas da frequências do sinal x_n indicam a evolução dessas frequências ao longo do tempo. Quando a derivada se anula, a frequência convergiu para um valor que obedece a regra de minimização. Sendo assim, de acordo com as equações 11, 12 e 13, as frequências, amplitudes e fases de x_n são obtidas de acordo com as equações 14, 15 e 16:

$$\frac{\frac{\Delta E}{\Delta n}}{\frac{\Delta E}{\Delta f_k}} = \frac{\Delta f_k}{\Delta n} \quad (11)$$

$$\frac{\frac{\Delta E}{\Delta n}}{\frac{\Delta E}{\Delta A_k}} = \frac{\Delta A_k}{\Delta n} \quad (12)$$

$$\frac{\frac{\Delta E}{\Delta n}}{\frac{\Delta E}{\Delta \Phi_k}} = \frac{\Delta \Phi_k}{\Delta n} \quad (13)$$

$$f_k = f_{k-1} - \frac{\frac{\Delta E}{\Delta n}}{\sum_{n=0}^{N-1} 2\pi n A_k \sin(2\pi n f_k + \Phi_k) d_n} \quad (14)$$

$$A_k = A_{k-1} + \frac{\frac{\Delta E}{\Delta n}}{\sum_{n=0}^{N-1} \cos(2\pi n f_k + \Phi_k) d_n} \quad (15)$$

$$\Phi_k = \Phi_{k-1} - \frac{\frac{\Delta E}{\Delta n}}{\sum_{n=0}^{N-1} A_k \sin(2\pi n f_k + \Phi_k) d_n} \quad (16)$$

4 Resultados e Conclusões

Para um conjunto de 10000 amostras, o método proposto foi implementado para se estimar um sinal composto por duas senóides, cujos parâmetros estão listados na Tabela 1.

Tabela 1: Estimação dos parâmetros de x_n

	Valor Real	Valor Inicial	Valor Estimado
A ₁	1.0	1.25	1.1299
A ₂	0.8	1.0	0.9215
f ₁	0.3	0.375	0.3762
f ₂	0.32	0.4	0.3988
Φ ₁	0.7854	1.1781	0.0804
Φ ₂	0.3927	0.589	-0.1170

Como estimativa inicial, escolheu-se valores 25% maiores para as amplitudes e frequências do sinal, enquanto que valores 50% maiores para as fases. A fase não teve um erro de convergência maior que os outros parâmetros, sendo este fato devido a um chute inicial maior, e em parte também porque a função a ser estimada tem múltiplos parâmetros e uma otimização multi-objetivo trataria este problema com conjuntos de soluções que minimizariam as soluções conflitantes.

5 Anexo

```

1 clear all
2 close all
3 clc

5 f = [0.30 0.32];
6 a = [1.0 0.8];
7 phi = [pi/4 pi/8];

9 n = [0: 1: 10000];

11 x1 = a(1)*cos(2*pi*f(1)*n+phi(1));
12 x2 = a(2)*cos(2*pi*f(2)*n+phi(2));
13 xn = x1+x2;

15 % figure(1), subplot (2,2,1), plot(n,x1),
16 % subplot (2,2,2), plot(n,x2),
17 % subplot (2,2,3), plot(n,xn);
18

21 ak = 1.25*a;
22 fk = 1.25*f;
23 phik = 1.5*phi;

25 y1 = ak(1)*cos(2*pi*fk(1)*n+phik(1));
26 y2 = ak(2)*cos(2*pi*fk(2)*n+phik(2));
27 yn=y1+y2;

29 dn=xn-yn;
30 for i=1:length(n)-1
31
32     y1 = ak(1)*cos(2*pi*fk(1)*n+phik(1));
33     y2 = ak(2)*cos(2*pi*fk(2)*n+phik(2));
34     yn=y1+y2;
35     dn = xn-yn;
36     deltaE = -2*pi*sum( (fk(1)*ak(1)*sin(2*pi*fk(1)+phik(1))+fk(2)*ak
37         (2)*sin(2*pi*fk(2)+phik(2))).*dn );

38     fk(1) = fk(1)-deltaE/sum( 2*pi.*n*ak(1).*sin(2*pi*fk(1)*n+phik(1)
39         ).*dn);
40     fk(2) = fk(2)-deltaE/sum( 2*pi.*n*ak(2).*sin(2*pi*fk(2)*n+phik(2)
41         ).*dn);

42     ak(1) = ak(1)+deltaE/sum( cos(2*pi*fk(1)*n+phik(1)).*dn);
43     ak(2) = ak(2)+deltaE/sum( cos(2*pi*fk(2)*n+phik(2)).*dn);

44     phik(1) = phik(1)-deltaE/sum( ak(1)*sin(2*pi*fk(1)*n+phik(1)).*dn
45         );
46     phik(2) = phik(2)-deltaE/sum( ak(2)*sin(2*pi*fk(2)*n+phik(2)).*dn
47         );
48 end

49 a, ak
50 f, fk

```

Referências

- [1] Lifang Han and Saroj K Biswas. Neural networks for sinusoidal frequency estimation. *Journal of The Franklin Institute*, 334(1):1–18, 1997.
- [2] John J Hopfield. Neurons with graded response have collective computational properties like those of two-state neurons. *Proceedings of the national academy of sciences*, 81(10):3088–3092, 1984.
- [3] Steven M Kay. *Modern spectral estimation*. Pearson Education India, 1988.
- [4] Steven M Kay and Stanley Lawrence Marple Jr. Spectrum analysis—a modern perspective. *Proceedings of the IEEE*, 69(11):1380–1419, 1981.